

Previsão de Rotatividade de Funcionários

Classificação Binária para Turnover com HR Analytics (Kaggle)

Disciplina: Machine Learning - Unidade 3

Dataset: HR Analytics - Kaggle (Giri Pujar) | CC0: Public Domain

Integrantes: Gabriel Freitas Souza, Indyanny Rodrigues Peixinho

1. Introdução e Relevância do Problema

Problema: Predição de saída voluntária de colaboradores (Turnover) usando aprendizado de máquina supervisionado.

Valor de Negócio (Retenção Estratégica):

A evasão de funcionários interrompe fluxos operacionais críticos e gera custos de rescisão, recrutamento e treinamento. A predição antecipada permite ao RH agir proativamente antes do pedido de desligamento.

- Tipo de Problema: Classificação Binária (Classe 1 = Saiu, Classe 0 = Ficou)
- Dataset: HR Analytics - Kaggle (Giri Pujar) - 14.999 registros, CC0: Public Domain
- Desafio Principal: Desbalanceamento (~76% ficou / ~24% saiu), exigindo métricas adequadas (F1-Score).

2. Obtenção e Preparação dos Dados

Dataset: HR Analytics - Kaggle (Giri Pujar) - 14.999 registros, 10 colunas, CC0: Public Domain.


Colunas originais (traduzidas para PT-BR):

- nivel_satisfacao, ultima_avaliacao, numero_projetos, media_horas_mensais
- tempo_empresa, acidente_trabalho, promocao_ultimos_5anos, departamento, salario
- saiu (variável alvo binária: 0 = ficou, 1 = saiu)
- Pré-processamento: Sem remoção de colunas (ausência de IDs ou vazamento de dados).
- Codificação One-Hot: variáveis categóricas 'departamento' e 'salario'.
- Normalização (StandardScaler): features numéricas contínuas.
- Particionamento: Divisão estratificada em 60% Treino (8.999), 20% Validação (3.000) e 20% Teste (3.000).

3. Análise Exploratória de Dados (EDA)

Principais Insights:

- Desbalanceamento moderado: ~76,4% ficou / ~23,6% saiu.
- Nível de satisfação muito baixo é o principal preditor de saída.
- Funcionários com excesso de horas mensais (>250h) ou carga insuficiente (<150h) saem mais.
- Salários baixos e falta de promoção nos últimos 5 anos correlacionam-se com turnover.
- Departamentos de Vendas e Técnico concentram mais desligamentos.



4. Eixo Analítico Secundário: Bike Sharing

Paradigma de Regressão Contínua: Transposição analítica usando o conjunto de dados da UCI para prever locações acumuladas de bicicletas (cnt).

Alerta de Data Leakage (Vazamento de Dados):

Remoção compulsória das colunas casual e registered. A soma de ambas equivale à variável alvo final. Mantê-las inviabilizaria o modelo preditivo real no mundo real.

- Pré-processamento: Exclusão de IDs ordinais (instant) e binarização de variáveis de clima/temporada via One-Hot encoding.
- Modelos: Regressão Linear Múltipla (OLS) vs Random Forest Regressor (ensemble não-linear por média de predições).

5. Modelos de Classificação e Hiperparâmetros

- Regressão Logística: Projeta probabilidades usando sigmoide e limites lineares. Otimizado hiperparâmetro de regularização C.
- Random Forest Classifier: Ensemble paralelo construído por Bagging de árvores de decisão. Hiperparâmetros: n_estimators e max_depth.
- Gradient Boosting Classifier: Treinamento sequencial onde cada árvore corrige os resíduos do conjunto anterior via gradiente.
- Estratégia class_weight='balanced': Atribuição de pesos inversamente proporcionais às frequências das classes, corrigindo o desbalanceamento.

Otimização: GridSearchCV com StratifiedKFold (5 folds) otimizando F1-Score.

6. Modelos de Regressão e Hiperparâmetros

- Regressão Linear Múltipla: Ajusta uma função de coeficientes lineares tentando encontrar a reta que minimiza a soma dos erros quadráticos.
- Random Forest Regressor: Combina múltiplas subárvores de regressão para reduzir a variância e prever o valor contínuo final através da média aritmética das predições de cada árvore.
- Otimização por GridSearchCV: Ambos os paradigmas (classificação e regressão) utilizam busca em grade com validação cruzada K-Fold (5 folds) na partição de treino para selecionar os parâmetros ideais.

7. Métricas de Avaliação e o Paradoxo da Acurácia

Métricas de Classificação (Turnover):

- Acurácia é enganosa em bases assimétricas.
- F1-Score é a métrica principal de seleção (harmonização de Precisão e Recall).
- Recall (Sensibilidade) é priorizado para o RH interceptar desligamentos.


Métricas de Regressão (Bike Sharing):

- RMSE (Root Mean Squared Error): Penaliza desvios residuais grandes elevados ao quadrado.
- MAE (Mean Absolute Error): Desvio médio linear tangível das locações.
- R^2 Score (Coeficiente de Determinação): Percentual explicativo da variância.

8. Resultados do Modelo de Turnover (Teste)

Métrica	Reg. Logística	Random Forest	Grad. Boosting	Melhor
Acurácia	0,9840	0,9860	0,9860	RF
Precisão	0,9508	0,9587	0,9757	GB
Recall	0,9831	0,9831	0,9647	RL
F1-Score	0,9667	0,9707	0,9702	RF
ROC-AUC	0,9989	0,9987	0,9992	GB

Modelo selecionado na validação (melhor Val F1): GradientBoosting.



9. Conclusão

- O pipeline de Machine Learning demonstrou eficácia na identificação de colaboradores com risco de desligamento usando o dataset HR Analytics (Kaggle).
- O nível de satisfação e a média de horas mensais são os atributos mais preditivos de turnover.
- Salário baixo e ausência de promoção nos últimos 5 anos amplificam significativamente o risco de saída.

Links do Repositório GitHub:

<https://github.com/Gabriel-Freitas-S/previsao-turnover-funcionarios>