

Previsao de Rotatividade de Funcionarios

Classificacao Binaria para Turnover Corporativo
IBM HR Analytics Employee Attrition & Performance

Disciplina: Machine Learning - Unidade 3

Dataset: IBM HR Analytics Employee Attrition & Performance

Integrantes: Gabriel Freitas Souza, Indyanny Rodrigues Peixinho

1. Definição do Problema

Problema: Prever se um funcionário tem alta probabilidade de deixar a empresa (Turnover). Trata-se de um problema de Classificação Binária:

- Classe Positiva (1): Funcionário saiu da empresa (Sim)
- Classe Negativa (0): Funcionário permaneceu (Não)

Relevância: A saída repentina de funcionários que dominam fluxos documentais críticos gera custos de recrutamento, perda de conhecimento institucional e riscos à conformidade legal. A retenção preditiva de talentos é uma prioridade estratégica para o RH.

2. Obtenção e Preparação dos Dados

Dataset: IBM HR Analytics Employee Attrition & Performance (Kaggle)

- 1470 registros, 35 atributos (23 numéricos, 7 categóricos restantes)
- 0 valores nulos - dados previamente higienizados e completos
- Variável alvo: Turnover (Sim/Não)

Pré-processamento:

- Remoção de colunas sem variância: ContagemFuncionarios, HorasPadrao, MaiorDe18
- Remoção do identificador: NumeroFuncionario
- Codificação One-Hot para variáveis categóricas (7 features)
- Padronização (StandardScaler) para variáveis numéricas
- ColumnTransformer + Pipeline para evitar vazamento de dados (data leakage)
- Divisão: 60% treino / 20% validação / 20% teste (estratificada)


3. Análise Exploratória dos Dados (EDA)

Distribuição da variável alvo - Desbalanceamento:

- 83,88% dos funcionários permanecem na empresa (Não)
- 16,12% dos funcionários saíram (Sim)
- 237 casos positivos vs 1233 casos negativos

Principais insights da EDA:

- Funcionários mais jovens apresentam maior propensão à saída
- Renda mensal mais baixa correlaciona fortemente com maior turnover
- Horas extras (HoraExtra) aumentam significativamente o risco
- Departamento de Vendas (Sales) tem maior taxa proporcional de turnover
- Cargos como Representante de Vendas e Técnico de Laboratório têm maior rotatividade



4. Metodologia - Modelos e Otimização

Modelos selecionados:

- Regressão Logística (class_weight='balanced') - Modelo linear interpretável
- Random Forest (class_weight='balanced') - Ensemble não-linear robusto
- Gradient Boosting - Ensemble não-linear baseado em boosting

Hiperparâmetros otimizados via GridSearchCV:

Regressão Logística:

- C (regularização inversa): [0.01, 0.1, 1, 10, 100]
- Penalty: L2 (Ridge)

Random Forest:

- n_estimators: [100, 200, 300]
- max_depth: [5, 10, None]
- min_samples_split: [2, 5]
- min_samples_leaf: [1, 2]

Gradient Boosting:

- n_estimators: [50, 100, 150]
- learning_rate: [0.01, 0.1, 0.2]
- max_depth: [3, 5]

Validação cruzada: StratifiedKfold (5 folds) no Treino

Métrica de otimização: F1-Score (classe minoritária)

Estratégia de balanceamento: `class_weight='balanced'` (onde aplicável)

5. Resultados e Comparação de Desempenho

Melhores hiperparâmetros encontrados:

Regressão Logística:

`C=0.1, penalty=L2, solver=lbfgs`

Random Forest:

`n_estimators=200, max_depth=5, min_samples_leaf=1`

Gradient Boosting:

`learning_rate=0.1, max_depth=3, n_estimators=150`

Comparação de Métricas (conjunto de teste):

Métrica	Reg. Logística	Random Forest	Grad. Boosting	Melhor
Acurácia	0,7619	0,8299	0,8605	GB
Precisão	0,3736	0,4717	0,5938	GB
Recall	0,7234	0,5319	0,4043	RL
F1-Score	0,4928	0,5000	0,4810	RF
ROC-AUC	0,7954	0,7615	0,8055	GB

5.1. Gráficos de Desempenho




Figura: Comparação de métricas, curva ROC, matrizes de confusão e importância de features.

6. Discussão dos Resultados

Análise comparativa:

- F1-Score e Recall: A Regressão Logística obteve melhor F1-Score (0,48) e Recall (0,72) no teste final, demonstrando maior capacidade de identificar funcionários que realmente vão sair da empresa.
- Acurácia: O Random Forest e Gradient Boosting obtiveram maior Acurácia (0,81 e 0,86), mas recall inferior, o que é enganoso devido ao forte desbalanceamento dos dados (84% permanecem).
- Conclusão: A Regressão Logística é mais indicada para este problema: prioriza a detecção de funcionários em risco (Recall maior de 0,72), essencial para que o RH possa agir proativamente.

Importância do F1-Score como métrica principal:

- Acurácia é enganosa em datasets desbalanceados (um modelo que chute 'não' teria 84% de acurácia)
- F1-Score equilibra Precisão e Recall para a classe minoritária
- `Class_weight='balanced'` foi crucial para melhorar a detecção da classe positiva

7. Conclusões e Melhorias

Conclusões:

- Melhor Modelo: O modelo de Regressão Logística com `class_weight='balanced'` apresentou o melhor equilíbrio entre detecção de saídas (Recall=0,72) e qualidade das predições (F1=0,48) no conjunto de teste.
- Fatores de Risco: Fatores mais relevantes para turnover: horas extras (HoraExtra), baixa renda (RendaMensal), distância de casa (DistanciaTrabalho), poucos anos de empresa e satisfação no trabalho.

Possíveis melhorias:

- Testar SMOTE como alternativa ao `class_weight='balanced'`
- Explorar outros algoritmos: XGBoost, LightGBM, SVM, Redes Neurais
- Coletar mais dados para melhorar a generalização
- Análise de features importantes para ações direcionadas de RH
- Implementação de sistema de alerta em tempo real

Referências e Repositório

Referências:

- IBM HR Analytics Employee Attrition & Performance - Kaggle
- Scikit-learn: Pipeline, GridSearchCV, ColumnTransformer
- Documentação: matplotlib, pandas, seaborn

Repositório do Projeto:

<https://github.com/Gabriel-Freitas-S/previsao-turnover-funcionarios>

Tecnologias: Python, scikit-learn, pandas, matplotlib, seaborn

Container: jupyter/scipy-notebook via Podman

Editor: Zed com Dev Containers