

Previsão de Rotatividade de Funcionários

Classificação Binária para Turnover de RH e Estudo de Caso Bike Sharing

Disciplina: Machine Learning - Unidade 3

Dataset: IBM HR Analytics Employee Attrition & Performance

Integrantes: Gabriel Freitas Souza, Indyanny Rodrigues Peixinho

1. Introdução e Relevância do Problema

Problema: Predição de saída voluntária de colaboradores (Turnover/Attrition) usando aprendizado de máquina supervisionado.

Valor de Negócio (Retenção Estratégica e Fluxos Documentais):

A evasão repentina de funcionários em posições-chave interrompe fluxos operacionais críticos e de faturamento. A predição atua mitigando custos de rescisão, recrutamento e perda do conhecimento institucional.

- Tipo de Problema: Classificação Binária (Classe 1 = Saiu, Classe 0 = Permaneceu)
- Desafio Principal: Lidar com o forte desbalanceamento nativo dos dados de RH (apenas ~16% de casos de saída).

2. Obtenção e Preparação dos Dados


Dataset: IBM HR Analytics Employee Attrition & Performance (1470 registros, 35 colunas).

- Limpeza Crítica: Remoção de atributos sem variância (StandardHours, EmployeeCount, Over18) e crachá (EmployeeNumber).
- Transformação de Atributos: Codificação One-Hot para variáveis categóricas qualitativas e Normalização (StandardScaler) para variáveis contínuas salariais e de tempo.
- Blindagem contra Vazamento (Data Leakage): Uso de ColumnTransformer e Pipeline ajustados estritamente na base de treino.
- Particionamento (SPEC): Divisão estratificada em 60% Treino (882), 20% Validação (294) e 20% Teste (294).

3. Análise Exploratória de Dados (EDA)

Mapeamento das Relações Organizacionais:

- Forte desbalanceamento nativo: 83,88% Não / 16,12% Sim.
- Horas Extras acumulam-se como o maior causador de evasão voluntária por estresse (Burnout).
- Salários baixos e início de carreira (poucos anos de casa) impulsionam transições externas.
- Vendas é o departamento com maior desgaste relativo.



4. Eixo Analítico Secundário: Bike Sharing

Paradigma de Regressão Contínua: Transposição analítica usando o conjunto de dados da UCI para prever locações acumuladas de bicicletas (cnt).

Alerta de Data Leakage (Vazamento de Dados):

Remoção compulsória das colunas casual e registered. A soma de ambas equivale à variável alvo final. Mantê-las inviabilizaria o modelo preditivo real.

- Pré-processamento: Exclusão de IDs ordinais (instant) e binarização de variáveis de clima/temporada via One-Hot encoding.
- Modelos: Regressão Linear Múltipla (OLS) vs Random Forest Regressor (ensemble não-linear por média de predições).

5. Modelos de Classificação e Hiperparâmetros

- Regressão Logística: Projeta probabilidades usando sigmoide e limites lineares. Otimizado hiperparâmetro de regularização C.
- Random Forest Classifier: Ensemble paralelo construído por agregação Bootstrap (Bagging) de árvores profundas. Hiperparâmetros: `n_estimators` e `max_depth`.
- Gradient Boosting Classifier: Treinamento sequencial onde cada árvore corrige os resíduos do conjunto anterior via gradiente.
- Estratégia de Custo Classweight: Atribuição de pesos inversamente proporcionais às frequências das classes (`class_weight='balanced'`) na Regressão Logística e Random Forest para calibrar o modelo contra a assimetria.

Melhores hiperparâmetros encontrados:

Regressão Logística: `C=0.1, penalty=L2, solver=lbfgs`

Random Forest: `n_estimators=200, max_depth=5, min_samples_split=5`

Gradient Boosting: `learning_rate=0.2, max_depth=3, n_estimators=100`

6. Modelos de Regressão e Hiperparâmetros

- Regressão Linear Múltipla: Ajusta uma função de coeficientes lineares tentando encontrar a reta que minimiza a soma dos erros quadráticos.
- Random Forest Regressor: Combina múltiplas subárvores de regressão para reduzir a variância e prever o valor contínuo final através da média aritmética das predições de cada árvore.
- Otimização por GridSearchCV: Ambos os paradigmas (classificação e regressão) utilizam busca em grade com validação cruzada K-Fold (5 folds) na partição de treino para selecionar os parâmetros ideais.

7. Métricas de Avaliação e o Paradoxo da Acurácia

Métricas de Classificação (Turnover):

- Acurácia é enganosa em bases assimétricas.
- F1-Score é a métrica principal de seleção (harmonização de Precisão e Recall).
- Recall (Sensibilidade) é priorizado para o RH interceptar desligamentos.


Métricas de Regressão (Bike Sharing):

- RMSE: Penaliza desvios residuais grandes elevados ao quadrado.
- MAE: Desvio médio linear tangível das locações.
- R^2 Score: Percentual explicativo da variância.

8. Resultados do Modelo de Turnover (Teste)

Métrica	Reg. Logística	Random Forest	Grad. Boosting	Melhor
Acurácia	0,7619	0,8299	0,8605	GB
Precisão	0,3736	0,4717	0,5938	GB
Recall	0,7234	0,5319	0,4043	RL
F1-Score	0,4928	0,5000	0,4810	RF
ROC-AUC	0,7954	0,7615	0,8055	GB

A Regressão Logística foi selecionada no conjunto de validação (Val F1=0,5441) e provê a melhor sensibilidade operacional (Recall de 72,34%).



9. Conclusão

- O modelo de Regressão Logística provou ser viável para antecipar evasões de talentos, permitindo ações proativas do RH (Recall = 72,34% no teste).
- Horas extras elevadas e remuneração mensal inferior destacam-se como os maiores alavancadores do desgaste corporativo.

Links do Repositório GitHub e Colab:

<https://github.com/Gabriel-Freitas-S/previsao-turnover-funcionarios>